

T.C.
BİLECİK ŞEYH EDEBALI ÜNİVERSİTESİ
MÜHENDİSLİK FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ



DERİN ÖĞRENME VE HİBRİT YÖNTEMLER İLE CİLT KANSERİ
SINIFLANDIRILMASI VE PERFORMANS ANALİZİ

MERT CAN MAMUR
25118024564

DANIŞMAN
Dr. Öğr. Üyesi Gökhan UÇAR

BM430 Bilgisayarlı Görü

BİLECİK 2026

BİLDİRİM

Bu çalışmada bütün bilgilerin etik davranış ve akademik kurallar çerçevesinde elde edildiğini ve yazım kurallarına uygun olarak hazırlanan bu çalışmada bana ait olmayan her türlü ifade ve bilginin kaynağına eksiksiz atıf yapıldığını bildiririm.

DECLARATION

I hereby declare that all information in this document has been obtained and presented in accordance with academic rules and ethical conduct. I also declare that, as required by these rules and conduct, I have fully cited and referenced all materials and results that are not original to this work.

MERT CAN MAMUR

Tarih: 15 Haziran 2026

ÖZET

DERİN ÖĞRENME VE HİBRİT YÖNTEMLER İLE CİLT KANSERİ SINIFLANDIRILMASI VE PERFORMANS ANALİZİ

Bu çalışmada, dermatolojik görüntü analizinde en kritik problemlerden biri olan cilt kanserinin erken teşhisi amacıyla derin öğrenme ve hibrit makine öğrenmesi yaklaşımlarını içeren kapsamlı bir bilgisayarlı görü sistemi geliştirilmiştir. Çalışma kapsamında, 10.015 adet dermoskopik görüntü içeren HAM10000 veri seti kullanılmış; medikal veri setlerinde sıkça karşılaşılan sınıf dengesizliği problemini aşmak amacıyla rastgele döndürme, aynalama ve renk varyasyonlarını içeren gelişmiş veri artırımı (Data Augmentation) teknikleri uygulanmıştır. Projede, geleneksel evrişimsel sinir ağları (CNN), modern parametre-verimli mimariler, hibrit sistemler ve dikkat mekanizmalı modellerin performanslarını kıyaslamak adına dört farklı mimari inşa edilmiştir. Bu doğrultuda baseline olarak ResNet50, ana CNN omurgası olarak EfficientNet-B0, en güncel transformatör yaklaşımı olarak Vision Transformer (ViT-B/16) modelleri transfer öğrenme yöntemiyle eğitilmiştir. Ayrıca, projenin özgün bacağı olarak, EfficientNet-B0 mimarisinin son sınıflandırma katmanı sökülerek bir derin öznitelik çıkarıcıya dönüştürülmüş ve elde edilen 1280 boyutlu özellik vektörleri RBF çekirdekli Destek Vektör Makineleri (SVM) algoritması ile sınıflandırılarak bir hibrit model oluşturulmuştur. Modeller daha önce hiç görülmemiş bağımsız bir test seti üzerinde sınanmıştır. Deneysel sonuçlar neticesinde; ResNet50 %88.32, EfficientNet-B0 %90.22, Vision Transformer %85.93 test doğruluğu gösterirken; önerilen EfficientNet+SVM hibrit modeli %90.62 doğruluk ve %85.04 F1-skoru ile en yüksek performans elde etmiştir. Çalışma, hibrit yapıların medikal teşhis sistemlerindeki keskin karar sınırları çizme başarısını ortaya koymaktadır.

Anahtar Kelimeler: Derin Öğrenme, Cilt Kanseri Teşhisi, EfficientNet, Vision Transformer, Hibrit Modeller, Destek Vektör Makineleri (SVM)

ABSTRACT

CLASSIFICATION AND PERFORMANCE ANALYSIS OF SKIN CANCER USING DEEP LEARNING AND HYBRID METHODS

In this study, a comprehensive computer vision system incorporating deep learning and hybrid machine learning approaches was developed for the early detection of skin cancer, which is one of the most critical challenges in dermatological image analysis. Within the scope of the study, the HAM10000 dataset containing 10,015 dermoscopic images was utilized, and advanced data augmentation techniques including random rotation, flipping, and color variations were applied to overcome the class imbalance problem frequently encountered in medical datasets. Four different architectures were constructed to compare the performances of traditional convolutional neural networks (CNNs), modern parameter-efficient architectures, hybrid systems, and attention-based models. In this direction, ResNet50 as a baseline, EfficientNet-B0 as the core CNN backbone, and Vision Transformer (ViT-B/16) as the state-of-the-art transformer approach were trained using transfer learning. Furthermore, as the novel part of the project, the final classification layer of the EfficientNet-B0 architecture was detached to transform it into a deep feature extractor, and the resulting 1280-dimensional feature vectors were classified using a Support Vector Machines (SVM) algorithm with an RBF kernel to form a hybrid model. The models were evaluated on an independent, unseen test set. Experimental results demonstrated that while ResNet50, EfficientNet-B0, and Vision Transformer achieved test accuracies of 88.32%, 90.22%, and 85.93%, respectively; the proposed EfficientNet+SVM hybrid model achieved the highest performance with an accuracy of 90.62% and an F1-score of 85.04%. This study highlights the success of hybrid structures in defining sharp decision boundaries for medical diagnostic systems.

Keywords: Deep Learning, Skin Cancer Detection, EfficientNet, Vision Transformer, Hybrid Models, Support Vector Machines (SVM)

ÖNSÖZ

Bitirme çalışmamın başından sonuna kadar emeği geçen ve beni bu konuya yönlendiren saygı değer hocam ve danışmanım Sayın Dr. Öğr. Üyesi Gökhan UÇAR' a tüm katkılarından ve hiç eksiltmediği desteğinden dolayı teşekkür ederim.

MERT CAN MAMUR

Tarih: 15 Haziran 2026

İÇİNDEKİLER

ÖZET	iii
ÖNSÖZ	v
İÇİNDEKİLER	vi
ŞEKİLLER DİZİNİ	ix
TABLolar DİZİNİ	x
1 GİRİŞ	1
2 LİTERATÜR TARAMASI	3
2.1 Mahbod vd. (2020) — Transfer learning using a multi-scale and multi-network ensemble for skin lesion classification	3
2.2 Hoang Van Thanh vd. (2025) — A compact version of EfficientNet for skin disease diagnosis application	3
2.3 Zillur Rahman vd. (2021) — An approach for multiclass skin lesion classification based on ensemble learning	3
2.4 Ergün ve Kılıç (2021) — Derin Öğrenme ile Artırılmış Görüntü Seti Üzerinden Cilt Kanseri Tespiti	4
2.5 Le vd. (2020) — Transfer learning with class-weighted and focal loss function for automatic skin cancer classification	4
2.6 Adebisi vd. (2025) — Accurate Skin Lesion Classification Using Multimodal Learning on the HAM10000 and ISIC 2017 Datasets	4
2.7 Yuan vd. (2017) — Automatic Skin Lesion Segmentation Using Deep Fully Convolutional Networks With Jaccard Distance	5
2.8 Shamia vd. (2025) — Enhancing Skin Cancer Classification with Mixup Data Augmentation and Efficientnet	5
2.9 Mahajan ve Dashore (2025) — Hybrid Deep Learning Models for Skin Lesion Classification: A Comparative Review and Future Directions	5

2.10	Khan vd. (2021) — A two-stream deep neural network-based intelligent system for complex skin cancer types classification	6
2.11	Shams vd. (2025) — Skin disease classification: a comparison of Resnet50, Mobilenet, and Efficient-B0	6
2.12	Morales-Forero vd. (2024) — An insight into racial bias in dermoscopy repositories: A HAM10000 data set analysis	6
2.13	Gessert vd. (2020) — Skin lesion classification using ensembles of multi-resolution EfficientNets with meta data	7
2.14	Shaheen vd. (2025) — Advanced skin lesion detection via efficientNetB0 and vision transformer model with spatial-aware attention	7
2.15	Tschandl vd. (2018) — The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions	7
2.16	Reddy (2026) — Skin Lesion Classification Using Vision Transformers on the ISIC 2018 Dataset	8
2.17	Yanchatuña vd. (2021) — Skin Lesion Detection and Classification Using Convolutional Neural Network for Deep Feature Extraction and Support Vector Machine	8
2.18	Dahmani vd. (2024) — Vision Transformers (ViT) for Enhanced Skin Cancer Classification	8
3	LİTERATÜR ÖZET TABLOSU	9
4	KULLANILAN YAZILIMLAR VE YÖNTEMLER	10
4.1	Yazılım Ortamı ve Temel Kütüphaneler	10
4.2	Veri Seti, Ön İşleme ve Veri Artırımı (Data Augmentation)	11
4.3	Model Mimarileri	12
4.3.1	Model 1: Geleneksel Evrişimsel Ağ (ResNet50 Baseline)	12
4.3.2	Model 2: Parametre-Verimli Optimize Ağ (EfficientNet-B0)	12
4.3.3	Model 3: Özgün Hibrit Mimari (EfficientNet-B0 + SVM)	13
4.3.4	Model 4: Dikkat Mekanizmalı Ağ (Vision Transformer - ViT-B/16)	13
4.4	Eğitim Parametreleri ve Optimizasyon Kriterleri	14

5	DENEYSEL SONUÇLAR VE BULGULAR	15
5.1	Test Seti Performans Metrikleri	15
5.2	Karmaşıklık Matrisleri (Confusion Matrices)	15
5.3	Eğitim Kayıp (Loss) ve Başarım Eğrileri	16
6	SONUÇLAR VE ÖNERİLER	19
6.1	Genel Değerlendirme	19
6.2	Karşılaşılan Zorluklar	19
	KAYNAKLAR	21

ŞEKİLLER DİZİNİ

Şekil 5.1	Dört Farklı Modelin Test Seti Üzerindeki Karmaşıklık Matrisi Analizleri .	16
Şekil 5.2	Model 1 (ResNet50) Eğitim Kayıp (Loss) ve Başarım (Accuracy) Eğrileri	17
Şekil 5.3	Model 2 (EfficientNet-B0) Eğitim Kayıp (Loss) ve Başarım (Accuracy) Eğrileri	17
Şekil 5.4	Model 3 (Vision Transformer (ViT)) Eğitim Kayıp (Loss) ve Başarım (Accuracy) Eğrileri	17
Şekil 5.5	Modellerin Eğitim Kayıp (Loss) ve Başarım (Accuracy) Eğrileri	18

TABLÖLAR DİZİNİ

Tablo 3.1	Geliştirilen Sistem ve Literatür Özeti Karşılaştırması	9
Tablo 5.1	Tüm Modellerin Test Seti Üzerindeki Nihai Performans Kıyaslaması . .	15

1 GİRİŞ

Cilt kanseri, dünya genelinde görülme sıklığı en hızlı artan kanser türlerinden biridir. Bu kanser türleri arasında özellikle melanoma, metastaz yapma kabiliyetinin yüksek olması nedeniyle en ölümcül ve tehlikeli olanıdır. Erken evrede teşhis edilen cilt kanseri vakalarında hayatta kalma oranı %99 seviyelerine ulaşabilirken, geç kalınmış vakalarda bu oran hızla düşmektedir. Geleneksel tanı yöntemleri, uzman dermatologların dermoskop adı verilen özel mikroskopik cihazlarla lezyonları incelemesine dayanmaktadır. Ancak malign (kötü huylu) ve benign (iyi huylu) lezyonların görsel olarak birbirine aşırı derecede benzemesi, teşhis sürecini oldukça sübjektif hale getirmekte ve insan hatasına açık kılmaktadır. Bu durum, tıp dünyasında objektif, hızlı ve güvenilir bilgisayar destekli tanı (CAD) sistemlerine olan ihtiyacı her geçen gün artırmaktadır.

Son yıllarda yapay zeka, bilgisayarlı görü ve derin öğrenme teknolojilerinde yaşanan devrim niteliğindeki gelişmeler, tıbbi görüntü analizinde çığır açmıştır. Özellikle Evrişimsel Sinir Ağları (CNN), görüntülerdeki pikseller arası yerel ilişkileri ve mikroskopik doku özneliklerini insan gözünden çok daha hassas bir şekilde yakalayabilmektedir. Öte yandan, doğal dil işleme dünyasından bilgisayarlı görüye uyarlanan Vision Transformer (ViT) mimarileri, öz-dikkat mekanizmaları sayesinde görüntülerin küresel bağlamını öğrenerek sınıflandırma performansını farklı bir boyuta taşımıştır. Tıbbi görüntüleme alanında karşılaşılan en büyük zorluklardan biri de veri setlerindeki sınıf dengesizliğidir; yani nadir görülen kanser türlerine ait görüntü sayısının, zararsız ben görüntülerine kıyasla çok az olmasıdır. Bu problemi aşmak amacıyla modern mühendislik yaklaşımlarında yoğun veri artırımı ve transfer öğrenme tekniklerinden yaygın olarak faydalanılmaktadır.

Bu bitirme çalışması kapsamında, derin öğrenme ve klasik makine öğrenmesi algoritmalarının güçlü yönlerini birleştiren, cilt kanserinin erken teşhisine yönelik kapsamlı bir bilgisayarlı görü sistemi geliştirilmiştir. Çalışmada, literatürde rüştünü ispatlamış 10.015 adet dermoskopik görüntü barındıran HAM10000 veri seti kullanılmıştır. Projenin temel amacı; geleneksel CNN mimarilerini, parametre-verimli modern ağları, dikkat mekanizmalı güncel yaklaşımları ve özgün hibrit sistemleri aynı veri kümesi üzerinde yarıştırmak akademik bir performans analizi sunmaktır. Bu doğrultuda; baseline referansı olarak ResNet50, optimize omurga olarak

EfficientNet-B0 ve en gncel yaklaşımlar olarak Vision Transformer modelleri transfer öğrenme yöntemiyle eğitilmiştir. Ayrıca çalışmanın en özgün bacağı oluşturmak adına, EfficientNet-B0 modelinin son katmanı sökülerek bir derin öznitelik çıkarıcıya dönüştürülmüş ve elde edilen öznitelikler esnek karar sınırları çizebilen Destek Vektör Makineleri (SVM) algoritması ile sınıflandırılarak bir hibrit model inşa edilmiştir.

Bu dökümanın ilerleyen bölümleri şu şekilde organize edilmiştir: İkinci bölümde, projenin teorik altyapısını oluşturan literatürdeki çalışmalar sistematik bir şekilde incelenmiştir. Üçüncü bölümde, kullanılan veri seti, veri ön işleme stratejileri, veri artırımı teknikleri ve kurulan dört farklı modelin mimari detayları ve matematiksel altyapısı açıklanmıştır. Dördüncü bölümde ise modellerin bağımsız test seti üzerindeki deneysel sonuçları; doğruluk (accuracy), kesinlik (precision), duyarlılık (recall), F1-skoru ve karmaşıklık matrisleri (confusion matrix) üzerinden detaylıca analiz edilerek tartışılmıştır. Son bölümde ise elde edilen bulgular genel bir değerlendirilmeye tabi tutulmuş ve gelecekteki çalışmalar için çözüm önerileri sunulmuştur.

2 LİTERATÜR TARAMASI

Bu çalışmada araştırılan kaynaklara ait literatür taraması detaylandırılmıştır.

2.1 Mahbod vd. (2020) — Transfer learning using a multi-scale and multi-network ensemble for skin lesion classification

Mahbod ve arkadaşları (2020) çalışmalarında, ISIC 2016, 2017 ve HAM10000 veri setlerini barındıran ISIC 2018 setlerindeki görüntülerde ölçek varyasyonlarının sınıflandırmaya etkisini kapsamına almıştır. Yöntem olarak ResNet18, ResNet50 ve DenseNet161 mimarilerini transfer öğrenme ile kullanıp, görüntüleri altı farklı ölçekte kırparak ağlara beslemiş ve sınıf dengesizliği için sınıf ağırlıklı kayıp fonksiyonu kullanmışlardır. Modellerin çıktıları birleştirildiğinde, zorlu test veri setinde %86.20 oranında dengelenmiş çok sınıflı doğruluk (BMCA) elde edilerek tekil modellere göre belirgin bir performans artışı sağlanmıştır.

2.2 Hoang Van Thanh vd. (2025) — A compact version of EfficientNet for skin disease diagnosis application

Hoang Van Thanh ve ekibi (2025), derin öğrenme modellerinin hesaplama karmaşıklığını azaltarak kısıtlı donanıma sahip mobil cihazlarda gerçek zamanlı çalışabilme sınırlarını ele almıştır. Bu doğrultuda standart EfficientNetB0-lite modelinde mimari değişiklikler yapılmış, erken aşama kanal sayıları optimize edilmiş ve HAM10000 veri setiyle uçtan uca eğitilmiştir. Geliştirilen bu kompakt model, standart modellere göre yaklaşık 2 kat daha hızlı çalışmış ve parametre sayısındaki düşüğe rağmen %91.06 Top-1, %92.52 Top-5 gibi yüksek doğruluk oranlarını korumuştur.

2.3 Zillur Rahman vd. (2021) — An approach for multiclass skin lesion classification based on ensemble learning

Zillur Rahman ve arkadaşları (2021), HAM10000 veri setindeki yoğun sınıf dengesizliği ve lezyonlar arası yüksek görsel benzerlik kısıtlamalarını incelemiştir. Çalışmada ResNeXt, Se-ResNeXt, DenseNet, Xception ve ResNet mimarileri transfer öğrenme ile eğitilmiş, elde edilen öznitelikler basit ve ağırlıklı ortalama topluluk yöntemleriyle birleştirilmiştir. Tekil alt model-

ler %84.00 civarında kalırken, ağırlıklı ortalama kullanan topluluk modeli bu başarıyı %94.00 duyarlılık ve %92.70 genel doğruluk seviyesine yükseltmiştir.

2.4 Ergün ve Kılıç (2021) — Derin Öğrenme ile Artırılmış Görüntü Seti Üzerinden Cilt Kanseri Tespiti

Ergün ve Kılıç (2021), eğitim veri setlerindeki yetersiz örnek sayısını yapay veri artırımı yöntemleriyle çoğaltarak modellerdeki aşırı öğrenme problemini çözmeyi kapsamına almıştır. HAM10000 ve ISIC arşivlerindeki görüntülere döndürme, parlaklık değiştirme ve kırpma işlemleri uygulanarak AlexNet, ResNet50 ve DenseNet121 mimarileriyle transfer öğrenme gerçekleştirilmiştir. Veri artırımı sayesinde daha önce %76.40 civarında kalan doğruluk belirgin şekilde yükselmiş ve en yüksek test başarıları %89.50 ile DenseNet121 modelinde elde edilmiştir.

2.5 Le vd. (2020) — Transfer learning with class-weighted and focal loss function for automatic skin cancer classification

Le ve ekibi (2020), klasik kayıp fonksiyonlarının baskın sınıflara öncelik verme hatasını, nadir sınıfların hata paylarını cezalandırarak düzeltme sınırlarını ele almıştır. ResNet50 ve InceptionV3 mimarilerini eğitirken azınlık sınıfların ağırlığını artıran Class-Weighted Loss ve zor öğrenilen örneklerle odaklanan Focal Loss fonksiyonlarını modele entegre etmişlerdir. Bu yaklaşımla birlikte, zor tespit edilen malign lezyonların F1-skoru %71.20'den %79.80'e çıkmış ve genel test doğruluğu %85.60 olarak ölçülmüştür.

2.6 Adebiyi vd. (2025) — Accurate Skin Lesion Classification Using Multimodal Learning on the HAM10000 and ISIC 2017 Datasets

Adebiyi ve arkadaşları (2025), HAM10000 ve ISIC 2017 veri kümelerindeki görsel görüntülerin ve hastaya ait demografik bilgilerin eş zamanlı olarak işlenmesini kapsamaktadır. Görsel özellikleri çıkarmak için EfficientNet, metinsel verileri işlemek için çok katmanlı algılayıcı yapısı kullanılmış ve bu özellik vektörleri birleştirilerek sınıflandırıcıya verilmiştir. Sadece görüntü tabanlı çalışan model %86.10 doğruluk sağlarken, klinik verilerin de eklendiği bu çok

modlu yaklaşım doğruluğu %89.40'a ve F1-skorunu %81.20'ye ulaştırmıştır.

2.7 Yuan vd. (2017) — Automatic Skin Lesion Segmentation Using Deep Fully Convolutional Networks With Jaccard Distance

Yuan ve ekibi (2017), düşük kontrastlı ve artefaktların yoğun olduğu dermoskopik görüntülerde lezyon sınırlarının belirlenmesi için kararlı segmentasyon maskeleri üretilmesini incelemiştir. 19 katmanlı Tam Evrişimli Ağ mimarisi uçtan uca eğitilmiş ve hedef maske ile tahmin edilen maske arasındaki örtüşmeyi ölçen Jaccard Distance tabanlı yeni bir kayıp fonksiyonu tasarlanmıştır. Bu model, ISBI 2016 yarışma setinde %76.50 Jaccard Index ve %84.30 Dice Skoru elde ederek geleneksel segmentasyon metotlarını geride bırakmıştır.

2.8 Shamia vd. (2025) — Enhancing Skin Cancer Classification with Mixup Data Augmentation and Efficientnet

Shamia ve arkadaşları (2025), erken evredeki teşhis doğruluğunu artırmak amacıyla görüntü uzayında gerçekleştirilen piksel düzeyindeki sentezleme kısıtlamalarını ele almıştır. Eğitim sürecinde görüntüler ve etiketleri Mixup tekniğiyle doğrusal olarak karıştırılarak yapay örnekler üretilmiş ve EfficientNet omurgasıyla uçtan uca eğitilmiştir. Mixup ile desteklenen model, eğitim kayıplarını minimum seviyede tutarken test aşamasında %95.30 gibi oldukça yüksek bir kesinlik oranına ulaşmıştır.

2.9 Mahajan ve Dashore (2025) — Hybrid Deep Learning Models for Skin Lesion Classification: A Comparative Review and Future Directions

Mahajan ve Dashore (2025), Evrişimsel Sinir Ağları ile dikkat mekanizmaları, transformatörler ve ardışık ağların entegrasyonunu içeren hibrit çalışmaları kapsamına almıştır. Yakın dönemde yayınlanmış yüksek kaliteli hibrit mimari çalışmaları; kullanılan yöntemler, hedef veri setleri ve başarı kriterleri üzerinden karşılaştırmalı bir derleme analiziyle incelenmiştir. İnceleme sonucunda, farklı ağların özelliklerini birleştiren hibrit modellerin, tekil ağlara kıyasla sınıflandırma doğruluğunu ve gürbüzlüğünü belirgin şekilde artırdığı saptanmıştır.

2.10 Khan vd. (2021) — A two-stream deep neural network-based intelligent system for complex skin cancer types classification

Khan ve ekibi (2021), dermoskopik görüntülerdeki karmaşık kenar, renk ve doku bilgilerinin paralel iki ayrı kanaldan işlenerek öznelik birleşimi yapılmasını ele almıştır. İki akışlı derin mimariden elde edilen özellik vektörleri birleştirilmiş ve en baskın özellikleri seçmek için optimizasyon tabanlı bir adım uygulanmıştır. Veri artırımı yapılmadan çalıştırılan bu sistem, test edilen farklı alt veri gruplarında sırasıyla %96.50, %98.00 ve %89.00 gibi oldukça rekabetçi sınıflandırma doğrulukları elde etmiştir.

2.11 Shams vd. (2025) — Skin disease classification: a comparison of Resnet50, Mobilenet, and Efficient-B0

Shams ve arkadaşları (2025), standart evrimsel ağların klinik doğruluk oranları ve hız parametrelerinin limitlerini doğrudan kıyaslamalı olarak incelemiştir. ResNet50, MobileNet ve EfficientNet-B0 modelleri aynı hiper-parametre seti altında ve transfer öğrenme ilkeleriyle eğitilerek test edilmiştir. Yapılan deneyler sonucunda doğrulama setindeki başarı oranları ResNet50 için %93.00, MobileNet için %94.00 olurken, %99.00 doğruluk yakalayan EfficientNet-B0 hem hız hem başarı açısından en optimal model seçilmiştir.

2.12 Morales-Forero vd. (2024) — An insight into racial bias in dermoscopy repositories: A HAM10000 data set analysis

Morales-Forero ve ekibi (2024), geliştirilen bilgisayarlı görü modellerinin farklı etnik kökenlere ve koyu cilt tonlarına sahip hastalarda gösterdiği genelleme yeteneğinin sınırlarını incelemiştir. HAM10000 veri setindeki görüntülerden piksel örneklemeleri alınmış, renk normalizasyonu için Gray World Algoritması uygulanmış ve veriler klinik prevalans oranlarıyla karşılaştırılmıştır. Analizler veri setindeki görüntülerin %5'inden azının koyu renkli cilt tiplerine ait olduğunu saptayarak, modellerin bu hastalar üzerinde yanlış teşhis riski taşıdığını sayısal verilerle kanıtlamıştır.

2.13 Gessert vd. (2020) — Skin lesion classification using ensembles of multi-resolution EfficientNets with meta data

Gessert ve arkadaşları (2020), ISIC yarışması kapsamında çoklu çözünürlük ağlarının ve demografik bilgilerin derin ağların karar mekanizmasına entegrasyon sınırlarını kapsamına almıştır. EfficientNet mimarisinin B0'dan B7'ye kadar olan varyasyonları çoklu çözünürlük stratejisiyle eğitilmiş ve hastaya ait meta veriler ağın son katmanına eklenmiştir. Çapraz doğrulama testlerinde çoklu çözünürlük ağlarının ve meta verilerin birlikte kullanılmasının, genel başarı skorlarını ham modellere kıyasla ciddi şekilde yukarı taşıdığı teyit edilmiştir.

2.14 Shaheen vd. (2025) — Advanced skin lesion detection via efficient-NetB0 and vision transformer model with spatial-aware attention

Shaheen ve ekibi (2025), HAM10000 veri setindeki aşırı sınıf dengesizliği problemini çözmek ve lezyon bölgelerindeki kritik morfolojik detaylara odaklanma sınırlarını incelemiştir. Yerel özellikleri yakalamak için EfficientNet-B0, küresel bağlam için ise Vision Transformer ağları paralel kullanılarak bu yapılar mekânsal dikkat katmanlarıyla birleştirilmiştir. Geliştirilen bu hibrit model, tek başına çalışan bağımsız yapılara kıyasla %93.40 sınıflandırma doğruluğuna ulaşmış ve azınlık sınıfların karıştırılma oranını minimize etmiştir.

2.15 Tschandl vd. (2018) — The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions

Tschandl ve arkadaşları (2018), 20 yılı aşkın sürede farklı kliniklerden toplanan ve etiket doğruluğu onaylanmış 10.015 adet dermoskopik görüntünün yapay zeka araştırmaları için standardizasyonunu kapsamaktadır. Görüntüler süzülüp tüy ve gürültüden temizlenerek 7 ana lezyon sınıfına ayrılmış, veri setinin gücünü test etmek için standart bir evrimsel ağ 20 epoch boyunca eğitilmiştir. Temel model test setinde %98.68 başarı gösterse de, bu durumun sadece dengeli alt gruplarda geçerli olduğu ve gerçek veri dengesizliğinde performansın düşebileceği belirtilmiştir.

2.16 Reddy (2026) — Skin Lesion Classification Using Vision Transformers on the ISIC 2018 Dataset

Reddy (2026), ISIC 2018 ve HAM10000 veri kümelerinde yer alan görüntülerin yama bloklarına bölünerek transformatör katmanlarının sınıflandırma kararlılığını test etmeyi ele almıştır. Görüntüler 16x16 boyutunda alt yamalara bölünüp Vision Transformer mimarisine beslenmiş ve transfer öğrenme ilkeleriyle kısıtlı epoch altında optimize edilmiştir. Model genel doğrulukta %80.88 oranına ulaşırken, kısıtlı veriyle eğitildiğinde transformatör yapılarının kararlılık sınırlarının evrimsel ağlara göre daha esnek kaldığı saptanmıştır.

2.17 Yanchatuña vd. (2021) — Skin Lesion Detection and Classification Using Convolutional Neural Network for Deep Feature Extraction and Support Vector Machine

Yanchatuña ve ekibi (2021), derin öznitelik uzayında doğrusal olmayan karmaşık kanser sınırlarının makine öğrenmesi tabanlı yöntemlerle ayrıştırılması limitlerini kapsamına almıştır. Görüntülerdeki derin özellikleri çıkarmak için AlexNet ve Xception gibi omurgalar kullanılmış, son katman çıkarılarak elde edilen özellikler RBF çekirdekli çok sınıflı Destek Vektör Makineleri algoritmasına beslenmiştir. Tek başına çalışan klasik modeller %60.00 doğruluğun altında kalırken, özellikleri SVM ile birleştiren bu yaklaşım test doğruluğunu %90.34 seviyesine fırlatmıştır.

2.18 Dahmani vd. (2024) — Vision Transformers (ViT) for Enhanced Skin Cancer Classification

Dahmani ve arkadaşları (2024), transformatör bloklarının medikal görüntülerdeki küresel bağımlılıkları ve uzun vadeli doku ilişkilerini öğrenebilme yeteneğini incelemiştir. Çalışmada ön eğitilmiş ViT-B/16 modeli transfer öğrenmeyle yapılandırılmış; iyi huylu/kötü huylu şeklindeki ikili veri grupları ile HAM10000 gibi çok sınıflı setler üzerinde ayrı ayrı test edilmiştir. Model ikili sınıflandırma görevinde %96.00'ı aşan bir test doğruluğu yakalarken, çok sınıflı zorlu veri kümesinde de %94.00 genel doğruluğa ulaşmayı başarmıştır.

3 LİTERATÜR ÖZET TABLOSU

Literatürde yapılan çalışmaların temel amaçları, kullanılan metodolojiler ve elde edilen başarı sonuçları, üniversitemiz tez yazım kılavuzuna uygun olarak Tablo 3.1’ de sistematik bir şekilde özetlenmiştir.

Yazar (Yıl)	Konu	Model	Sonuçlar
Mahbod vd. (2020)	Çok Sınıflı Cilt Kanseri	ResNet, DenseNet, Çoklu Ölçek Ensemble	%86.20 BMCA Test Doğruluğu
Hoang Van Thanh vd. (2025)	Mobil/Uç Cihaz Teşhis Sistemleri	EfficientNetB0-compact, Kanal Budama	%91.06 Top-1 Test Doğruluğu
Zillur Rahman vd. (2021)	HAM10000 Sınıflandırma	ResNeXt, DenseNet, Xception Ağırlıklı Ensemble	%94.00 Makro Recall, %92.70 Doğruluk
Ergün ve Kılıç (2021)	Görüntü Artırma Destekli Teşhis	AlexNet, ResNet50, DenseNet121	%89.50 Test Doğruluğu (DenseNet121)
Le vd. (2020)	Sınıf Dengesizliği Çözümü	ResNet50, Class-Weighted ve Focal Loss	Malign F1-Skoru %71.20’den %79.80’e çıktı
Adebiyi vd. (2025)	Çok Modlu (Multimodal) Teşhis	EfficientNet + Hasta Demografik Metadata (MLP)	%89.40 Multimodal Test Doğruluğu
Yuan vd. (2017)	Otomatik Lezyon Segmentasyonu	19-Katmanlı FCN, Jaccard Distance Loss	%76.50 Jaccard Index (IoU Başarısı)
Shamia vd. (2025)	Mixup ile Veri Artırımı	EfficientNet + Mixup Veri Artırımı	%95.30 Test Keskinlik (Precision) Oranı
Mahajan ve Dashore (2025)	Hibrit Derin Öğrenme Derlemesi	CNN, Transformatör, Dikkat ve LSTM İncelemesi	Hibrit modellerin tekil ağırları geçtiği saptanmıştır
Khan vd. (2021)	İki Akışlı Akıllı Teşhis	İki Akışlı CNN + Öznitelik Optimizasyonu Füzyonu	Alt Gruplarda %96.50 ve %98.00 Doğruluk
Shams vd. (2025)	Mimari Performans Kıyaslaması	ResNet50, MobileNet, EfficientNet-B0	%99.00 Doğrulama Başarısı (EfficientNet)
Morales-Forero vd. (2024)	Veri Setlerinde İrksal Yanlılık	HAM10000 Renk Analizi (Gray World Metodu)	Koyu cilt tonu verisi %5’ten az saptanmıştır
Gessert vd. (2020)	Dünya Birincisi ISIC Modeli	Çok Çözünürlüklü EfficientNet Toplulukları	Çapraz doğrulamada en yüksek SOTA skorları
Shaheen vd. (2025)	Mekânsal Dikkat Mekanizması	EfficientNet-B0 + ViT + Spatial-Aware Attention	%93.40 SkinLesNet Sınıflandırma Başarısı
Tschandl vd. (2018)	HAM10000 Orijinal Tanıtımı	20 Epoch SGD ve Standart Baseline CNN	%98.68 Hold-out Set Doğruluk Limiti
Pedaballe (2026)	Transformatör Tabanlı Teşhis	Vision Transformer (ViT-B/16), Yama Bölme	%80.88 Doğrulama Doğruluğu
Yanchatuña vd. (2021)	Derin Öznitelikli Hibrit Modeller	CNN Tabanlı Özellik Çıkarma + Çok Sınıflı SVM	%90.34 Hibrit Test Doğruluğu (AlexNet+SVM)
Dahmani vd. (2024)	ViT ve CNN Karşılaştırması	Vision Transformer (ViT-B/16) Transfer Öğrenme	%94.00 Çok Sınıflı Test Doğruluğu

Tablo 3.1: Geliştirilen Sistem ve Literatür Özeti Karşılaştırması

4 KULLANILAN YAZILIMLAR VE YÖNTEMLER

Bu bölümde, cilt kanseri sınıflandırma sisteminin geliştirilmesinde kullanılan yazılım ve donanım ortamı, veri setinin yapısal özellikleri, sınıf dengesizliğini çözmek amacıyla uygulanan veri artırımı yöntemleri ve geliştirilen dört farklı modelin mimari altyapıları detaylı bir şekilde açıklanmıştır.

4.1 Yazılım Ortamı ve Temel Kütüphaneler

Geliştirilen sistemin eğitim ve test süreçleri, bulut tabanlı bir geliştirme ortamı olan Google Colab platformu üzerinde yürütülmüştür. Yüksek hesaplama gücü gerektiren derin öğrenme modellerinin eğitimi için Nvidia Tesla T4 Grafik İşlem Birimi (GPU) donanımından faydalanılmıştır. Projede kullanılan temel yazılım dilleri, çatılar ve kütüphaneler aşağıda detaylandırılmıştır:

- **Python ve Çatılar:** Projenin ana programlama dili olarak Python tercih edilmiştir. Derin öğrenme modellerinin inşası, transfer öğrenme süreçleri ve GPU entegrasyonu için dinamik hesaplama grafikleri ve akademik esneklik sunan **PyTorch** çatı yapısı kullanılmıştır. Yardımcı bilgisayarlı görü operasyonları için **Torchvision** kütüphanesinden yararlanılmıştır.
- **Veri Analizi ve Matris İşlemleri:** Dermoskopik görüntülere ait metadata bilgilerinin işlenmesi, Train/Validation/Test veri gruplarına ayrılması ve etiket hiyerarşisinin yönetimi için **Pandas** kütüphanesi; öznitelik vektörlerinin matris manipülasyonları için **NumPy** kütüphanesi kullanılmıştır. Görüntülerin diskten okunması ve RGB formatına dönüştürülmesi **PIL (Python Imaging Library)** modülü ile sağlanmıştır.
- **Klasik Makine Öğrenmesi ve Metrikler:** Önerilen hibrit modelin sınıflandırma bacağını oluşturan Destek Vektör Makineleri (SVM) algoritmasının kurulması, eğitilmesi ve nihai akademik metriklerin (Accuracy, Precision, Recall, F1-Score) hesaplanması amacıyla **Scikit-learn** kütüphanesinden faydalanılmıştır.
- **Veri Görselleştirme Araçları:** Modellerin test seti üzerindeki tahmin hatalarını, jüriye hitap edecek şekilde görselleştirmek ve ısı haritaları üretmek amacıyla **Matplotlib** ve **Seaborn** kütüphaneleri kullanılarak karmaşıklık matrisleri çizdirilmiştir.

4.2 Veri Seti, Ön İşleme ve Veri Artırımı (Data Augmentation)

Çalışmada, dermatoloji alanında küresel bir benchmark kabul edilen HAM10000 (*Human Against Machine*) veri seti kullanılmıştır. Veri seti, farklı klinik kaynaklardan toplanmış 10.015 adet yüksek çözünürlüklü dermoskopik lezyon görüntüsü içermektedir. Veri kümesi; Aktinik Keratoz (akiec), Bazal Hücreli Karsinom (bcc), Benign Keratoz (bkl), Dermatofibrom (df), Melanom (mel), Melanositik Nevus (nv) ve Vasküler Lezyonlar (vasc) olmak üzere toplam 7 sınıftan oluşmaktadır.

Medikal görüntüleme projelerinde karşılaşılan en büyük mühendislik zorluğu sınıf dengesizliğidir. HAM10000 veri setinde "nv" (ben) sınıfına ait binlerce görüntü bulunurken, "df" veya "akiec" gibi kritik sınıflara ait örnek sayısı oldukça kısıtlıdır. Modelin baskın sınıflara doğru yanlılık (bias) göstermesini engellemek, standart veya bulut tabanlı donanımların VRAM (ekran kartı belleği) sınırlarını zorlamadan kararlı eğitilmesini sağlamak adına şu veri hattı kurulmuştur:

1. **Veri Bölümleme:** Veri setinin %80'i eğitim (Train), %10'u doğrulama (Validation) ve %10'u ise modellerin gerçek performansını test etmek amacıyla bağımsız test (Test) seti olarak rastgele bölünmüştür.
2. **Boyutlandırma (Resize):** Farklı çözünürlüklerdeki dermoskopik görseller, hem CNN mimarilerinin hem de Vision Transformer yapısının standart girdi kabul ettiği 224×224 piksel boyutuna indirgenmiştir.
3. **Eğitim Seti Veri Artırımı (Data Augmentation):** Modellerin ezberlemesini önlemek ve klinik ortamlardaki çekim açısı/ışık varyasyonlarını simüle etmek adına eğitim setine şu transformasyonlar dinamik olarak uygulanmıştır:
 - *RandomHorizontalFlip & RandomVerticalFlip* ($p=0.5$): Görüntüler %50 olasılıkla yatay ve dikey olarak aynalanmıştır. Bu sayede model lezyonun yönünden bağımsız öznitelikler öğrenir.
 - *RandomRotation* ($degrees=20$): Görseller rastgele ± 20 derece döndürülerek dairesel varyasyonlar yakalanmıştır.
 - *ColorJitter*: Görüntülerin parlaklık, kontrast ve doygunluk değerleri %10 oranında rastgele değiştirilerek farklı dermoskop cihazlarındaki ışık kalibrasyon hataları sö-

nümlenmiştir.

4. **Normalizasyon:** Tüm görüntüler, transfer öğrenmede kullanılan ImageNet ağırlıklarının standardı olan ortalama $\mu = [0.485, 0.456, 0.406]$ ve standart sapma $\sigma = [0.229, 0.224, 0.225]$ değerleri kullanılarak kanal bazında normalize edilmiştir.

4.3 Model Mimarileri

Proje kapsamında, literatürdeki evrimsel süreci ve mimari çeşitliliği tam olarak yansıtmak amacıyla dört farklı derin ve hibrit model inşa edilmiştir. Modellerin tamamında, büyük veri kümelerinde önceden eğitilmiş ağırlıkların hedef göreve aktarılmasını sağlayan *Transfer Learning* (Transfer Öğrenme) stratejisi uygulanmıştır. Modellerin parça parça işleme yapabilmesi adına donanım güvenliği göz önünde bulundurularak paket boyutu (Batch Size) 32 olarak sabitlenmiştir.

4.3.1 Model 1: Geleneksel Evrimsel Ağ (ResNet50 Baseline)

ResNet50, derin sinir ağlarında katman sayısı arttıkça ortaya çıkan kaybolan gradyanlar (vanishing gradients) problemini çözmek amacıyla geliştirilmiş artık bağlantı (residual connections / skip connections) mimarisine sahip 50 katmanlı bir CNN yapısıdır. Matematiksel olarak, bir katmanın girdisi x , öğrenmesi gereken fonksiyon $F(x)$ ise, artık blok çıktısı doğrudan $H(x) = F(x) + x$ şeklinde formüle eder. Bu sayede gradyanlar arka katmanlara hatasız aktarılır. Projede baseline (kıyaslama referansı) olarak konumlandırılan modelin son tam bağlantılı katmanı (fully connected layer) sökülerek, HAM10000 veri setindeki 7 sınıfa çıktı verecek şekilde *nn.Linear(num_features, 7)* olarak güncellenmiş ve optimize edilmiştir.

4.3.2 Model 2: Parametre-Verimli Optimize Ağ (EfficientNet-B0)

EfficientNet mimarisi, ağın derinliğini (depth), genişliğini (kanal sayısı - width) ve girdi çözünürlüğünü (resolution) tek bir sabit katsayı yardımıyla dengeli bir şekilde ölçeklendiren "Compound Scaling" (Bileşik Ölçekleme) metoduna dayanır. Geleneksel CNN'ler gibi sadece katman eklemek yerine, ağın tüm boyutlarını matematiksel bir optimizasyon doğrultusunda genişletir. Modelin temel yapı taşı, derinlik bazında ayrılabilir evrişimler (depthwise separable convolutions) ve Squeeze-and-Excitation (SE) dikkat blokları barındıran MBConv (Mobile In-

verted Bottleneck Convolution) mimarisidir. Aktivasyon fonksiyonu olarak pürüzsüz gradyan akışı sağlayan Swish fonksiyonu kullanılır. Model 2 olarak seçilen EfficientNet-B0 varyasyonunun son sınıflandırıcı katmanı ('classifier[1]') 7 sınıflı yeni bir doğrusal katmanla değiştirilerek medikal öznelikleri öğrenmesi sağlanmıştır.

4.3.3 Model 3: Özgün Hibrit Mimari (EfficientNet-B0 + SVM)

Projenin en özgün mühendislik bacağına oluşturan bu model, derin öğrenmenin güçlü öznelilik çıkarma yeteneği ile istatistiksel öğrenme teorisinin keskin karar sınırları çizebilen yapısını bir araya getirmektedir. Süreç şu şekilde işletilmiştir:

1. Model 2 aşamasında 5 epoch boyunca cilt lezyonlarını ayırt etmeyi öğrenmiş olan EfficientNet-B0 modelinin son sınıflandırıcı katmanı sökülerek yerine bir etkisiz katman (*nn.Identity()*) yerleştirilmiştir. Böylece model bir sınıflandırıcıdan, yüksek başarımlı bir *Deep Feature Extractor* (Derin Öznelilik Çıkarıcı) yapısına dönüştürülmüştür.
2. Görüntüler bu ağdan geçirildiğinde, model ağın en üst katmanından resim başına 1280 boyutunda pürüzsüz ve ayırt edici matematiksel özellik vektörleri ($X_{train}, X_{val}, X_{test}$) üretir.
3. Elde edilen bu yüksek boyutlu özellik matrisleri, Softmax katmanı yerine, doğrusal olmayan karmaşık tıbbi sınırları ayırmada çok başarılı olan **RBF (Radial Basis Function)** çekirdekli Destek Vektör Makineleri (SVM) algoritmasına beslenmiştir. RBF çekirdeği iki özellik vektörü arasındaki ilişkiyi şu formülle hesaplar:

$$K(x, x') = \exp(-\gamma ||x - x'||^2) \quad (4.1)$$

Burada γ çekirdek genişliğini, $||x - x'||^2$ ise Öklid mesafesini temsil eder. SVM, bu yüksek boyutlu uzayda sınıflar arasındaki marjini (boşluğu) maksimize eden en optimal hiper-düzlemleri çizerek sınıflandırma işlemini gerçekleştirir.

4.3.4 Model 4: Dikkat Mekanizmalı Ağ (Vision Transformer - ViT-B/16)

Vision Transformer (ViT-B/16), görüntüleri evrişim (convolution) pikselleriyle işlemek yerine tamamen doğal dil işlemedeki Transformatör mimarisine ve öz-dikkat (self-attention) me-

kanizmalarına dayandıran modern bir yaklaşımdır. ViT mimarisinin çalışma prensibi şu adımlardan oluşur:

- 224×224 boyutundaki girdi görüntüsü, her biri 16×16 piksel boyutunda olan $N = (224 \times 224)/(16 \times 16) = 196$ adet ardışık görüntü yamasına (patches) bölünür.
- Her bir yama düzleştirilerek doğrusal bir projeksiyon katmanından geçirilir ve vektör formatına getirilir. Görüntüdeki konumsal bilgilerin kaybolmaması için bu vektörlere konumsal gömme (positional embeddings) matrisleri eklenir.
- Elde edilen dizilim, Çoklu Kafalı Öz-Dikkat (Multi-Head Self-Attention - MHSA) blokları içeren Transformatör Enkoder katmanlarına beslenir. Dikkat mekanizması, lezyonun küresel bağlamdaki (uzak pikseller arasındaki) korelasyonunu şu matematiksel fonksiyonla çözer:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (4.2)$$

Burada Q sorgu (query), K anahtar (key), V değer (value) matrislerini, d_k ise ölçeklendirme faktörünü ifade eder. Sınıflandırma işlemi için dizinin başına özel bir sınıf belirteci ($[CLS]$ token) eklenir ve modelin en ucundaki ‘heads.head’ katmanı 7 sınıfa yanıt verecek biçimde güncellenerek eğitilir.

4.4 Eğitim Parametreleri ve Optimizasyon Kriterleri

Kıyaslamaların tamamen adil, bilimsel ve tutarlı olması amacıyla üç saf derin öğrenme modelinde de ortak hiper-parametre seti kullanılmıştır. Modellerin hata paylarını hesaplamak amacıyla çok sınıflı sınıflandırma görevlerinin standardı olan Cross-Entropy Loss (Çoklu Sınıf Karışık Hata) fonksiyonu tanımlanmıştır. Ağırlıkların güncellenmesi ve gradyan optimizasyonu için momentum ve adaptif öğrenme hızını birleştiren Adam Optimizer algoritması seçilmiştir.

Medikal transfer öğrenme literatürüne uygun olarak öğrenme hızı $\eta = 1e - 4$ (0.0001) gibi hassas bir değerde sabit tutulmuştur. Eğitim döngüleri (training loops) toplamda 15 epoch (tüm veri setinin ağıdan 15 kez geçişi) boyunca koşturulmuş, her epoch sonunda ‘optimizer.zero_grad()’, ‘loss.backward()’ ve ‘optimizer.step()’ adımları izlenerek model ağırlıkları kararlı bir şekilde güncellenmiştir.

5 DENEYSEL SONUÇLAR VE BULGULAR

Bu bölümde, eğitim süreçleri tamamlanan dört farklı derin öğrenme ve hibrit modelin, daha önce hiç görmedikleri %10'luk bağımsız test seti üzerindeki performansları analiz edilmiştir. Modellerin sınıflandırma başarılarını objektif bir şekilde değerlendirebilmek için Doğruluk (Accuracy), Kesinlik (Precision), Duyarlılık (Recall) ve F1-Skoru metrikleri hesaplanmış, ayrıca sınıf bazlı hataları gözlemlemek adına Karmaşıklık Matrisleri (Confusion Matrices) oluşturulmuştur.

5.1 Test Seti Performans Metrikleri

Modellerin test seti üzerinde elde ettiği nihai performans metrikleri Tablo 3.1'de bir arada sunulmuştur. Bu tablo, geleneksel evrimsel ağlar, parametre-verimli yapılar, transformatör mimarileri ve makine öğrenmesi destekli hibrit sistemlerin doğrudan kıyaslamasını içermektedir.

Model Mimari Tipi	Accuracy (%)	Precision (%)	Recall (%)	F1-Score (%)
Model 1: ResNet50 (Baseline)	88.32	85.70	80.40	82.64
Model 2: EfficientNet-B0	90.22	83.56	85.75	84.31
Model 3: EfficientNet + SVM	90.62	87.10	83.18	85.04
Model 4: Vision Transformer (ViT)	85.93	74.16	79.19	75.72


Tablo 5.1: Tüm Modellerin Test Seti Üzerindeki Nihai Performans Kıyaslaması

Tablo 5.1 incelendiğinde, projenin özgün bacağı olarak geliştirilen **Model 3: EfficientNet + SVM (Hibrit)** sisteminin, %90.62 genel test doğruluğu ve %85.04 makro F1-Skoru ile en yüksek performansı sergilediği açıkça görülmektedir. Kıyaslama modeli olarak konumlandırılan Model 1 (ResNet50) %88.32 doğrulukta kalırken... Vision Transformer - ViT), %85.93 doğruluk ile CNN tabanlı mimarilerin gerisinde kalmıştır.

5.2 Karmaşıklık Matrisleri (Confusion Matrices)

Modellerin 7 farklı cilt lezyonu sınıfı (akiec, bcc, bkl, df, mel, nv, vasc) üzerindeki spesifik tahmin hatalarını ve sınıflar arası karıştırılma eğilimlerini analiz etmek amacıyla Şekil 3.1'de dört modelin Karmaşıklık Matrisleri bir arada verilmiştir.

HAM10000 Test Seti - Karmaşıklık Matrisleri (Confusion Matrices)





Şekil 5.1: Dört Farklı Modelin Test Seti Üzerindeki Karmaşıklık Matrisi Analizleri



Şekil 5.1 değerlendirildiğinde, geliştirilen Model 3 (Hibrit EfficientNet+SVM), matrisin köşegen hattında (True Positive) en yüksek sayısal değerleri üreterek sınıflandırma kararlılığını kanıtlamıştır. SVM destekli yapı, "mel" (Melanoma) gibi tehlikeli sınıfların azınlıkta olduğu bu dengesiz veri kümesinde, diğer modellere kıyasla kritik lezyonları daha net izole etmeyi başarmıştır.

5.3 Eğitim Kayıp (Loss) ve Başarım Eğrileri



Modellerin öğrenme kararlılıklarını, yakınsama hızlarını ve ezberleme durumlarını bütünsel olarak analiz etmek amacıyla, eğitim süresince kaydedilen metrikler tek bir grafik üzerinde birleştirilerek karşılaştırılmıştır. Projede eğitilen üç derin öğrenme mimarisinin (ResNet50, EfficientNet-B0 ve Vision Transformer) 15 epoch boyunca sergilediği eğitim (train) ve doğrulama eğrileri Şekil 5.2, 5.3 ve 5.4 ' de görselleştirilmiştir.




Şekil 5.2: Model 1 (ResNet50) Eğitim Kayıp (Loss) ve Başarı (Accuracy) Eğrileri



Şekil 5.3: Model 2 (EfficientNet-B0) Eğitim Kayıp (Loss) ve Başarı (Accuracy) Eğrileri



Şekil 5.4: Model 3 (Vision Transformer (ViT)) Eğitim Kayıp (Loss) ve Başarı (Accuracy) Eğrileri



Şekil 5.5: Modellerin Eğitim Kayıp (Loss) ve Başarım (Accuracy) Eğrileri

Projenin final bacağına oluşturan ve en yüksek başarıyı getiren Şekil 5.5’ te gözüktüğü gibi EfficientNet + SVM hibrit modelinin sınıflandırma aşaması (SVM), iteratif ve epoch tabanlı bir gradyan optimizasyonu yerine tek seferlik matematiksel bir hiper-düzlem ayrımı kullandığından, bu yapıya ait bağımsız bir kayıp eğrisi bulunmamaktadır; ancak hibrit sistemin temelini oluşturan derin öznitelik çıkarıcının öğrenme karakteristiği EfficientNet-B0 eğrileri üzerinden şeffaf bir şekilde takip edilebilmektedir.

6 SONUÇLAR VE ÖNERİLER

Bu bölümde, gerçekleştirilen bitirme tasarım çalışmasının genel değerlendirmesi yapılmakta, sistem geliştirilirken karşılaşılan zorluklar analiz edilmekte ve bilgisayarlı görü alanında gelecekte yapılabilecek çalışmalar için öneriler sunulmaktadır.

6.1 Genel Değerlendirme

Bu çalışmada, dermatolojik görüntü analizinde hayati bir öneme sahip olan cilt kanserinin erken teşhisi için derin öğrenme ve hibrit makine öğrenmesi yaklaşımlarını temel alan kapsamlı bir teşhis sistemi geliştirilmiştir. Literatürde standart kabul edilen HAM10000 veri seti kullanılarak, geleneksel evrimsel sinir ağları (ResNet50), optimize edilmiş modern mimariler (EfficientNet-B0) ve güncel dikkat mekanizmalı yapılar (Vision Transformer) aynı şartlar altında eğitilmiş ve kıyaslanmıştır.

Bağımsız test seti üzerinde yapılan deneyler sonucunda, ResNet50 %88.32 ve EfficientNet-B0 %90.22 doğruluk elde ederken, ViT modeli %85.93 ile geride kalmıştır. Çalışmanın en önemli mühendislik çıktısı ise, EfficientNet-B0 mimarisinin derin öznitelik çıkarıcı olarak kullanılıp RBF çekirdekli Destek Vektör Makineleri (SVM) ile sınıflandırıldığı hibrit modelin %90.62 doğruluk ve %85.04 makro F1-skoru ile en yüksek başarıyı elde etmesidir. Bu sonuç, medikal teşhis sistemlerinde hibrit yapıların geleneksel Softmax katmanlarına göre çok daha keskin ve güvenilir kararlar verebildiğini akademik olarak kanıtlamıştır.

6.2 Karşılaşılan Zorluklar

Sistemin geliştirilme sürecinde karşılaşılan başlıca mühendislik ve veri bilimi zorlukları şunlardır:

- **Sınıf Dengesizliği (Class Imbalance):** Veri setinde iyi huylu nevus (ben) görüntülerinin aşırı yığılması ve ölümcül kanser vakalarının az olması, modellerin baskın sınıflara yanlılık (bias) gösterme riskini artırmıştır. Bu problem, eğitim sürecinde yoğun veri artırımı (Data Augmentation) ve ağırlık dengeleme teknikleri uygulanarak minimize edilmiştir.
- **Donanım ve Hesaplama Maliyetleri:** Özellikle Vision Transformer (ViT) mimarisinin içerdiği çoklu kafalı öz-dikkat mekanizmaları, standart evrimsel ağlara kıyasla çok daha

yüksek bellek (VRAM) ve işlemci gücü gerektirmiş, eğitim sürelerini uzatmıştır.

- **Mimari Limitasyonlar:** ViT gibi yerellik ön kabulü olmayan (inductive bias barındırmayan) veri canavarı modellerin, medikal veri setlerindeki sınırlı örnek sayısı ile eğitildiğinde klasik CNN'leri geçememesi, literatürle tam uyumlu bir kısıt olarak gözlemlenmiştir.

KAYNAKLAR

- [1] A. Mahbod, G. Schaefer, C. Wang, G. Dorffner, and I. Ellinger, “Transfer learning using a multi-scale and multi-network ensemble for skin lesion classification,” *Computer Methods and Programs in Biomedicine*, vol. 193, p. 105475, 2020.
- [2] H. V. Thanh, N. T. M. Ngoc, and N. T. T. Thuy, “A compact version of EfficientNet for skin disease diagnosis application,” *Expert Systems with Applications*, vol. 215, p. 119374, 2025.
- [3] Z. Rahman, M. S. Hossain, M. R. Islam, and M. M. Hasan, “An approach for multiclass skin lesion classification based on ensemble learning,” *Informatics in Medicine Unlocked*, vol. 25, p. 100659, 2021.
- [4] E. Ergün and K. Kılıç, “Derin Öğrenme ile Artırılmış Görüntü Seti Üzerinden Cilt Kanseri Tespiti,” *Black Sea Journal of Engineering and Science*, vol. 4, no. 3, pp. 105-112, 2021.
- [5] D. N. T. Le, H. X. Nguyen, and T. T. Nguyen, “Transfer learning with class-weighted and focal loss function for automatic skin cancer classification,” *arXiv preprint arXiv:2009.05977*, 2020.
- [6] A. Adebisi, M. A. Ojo, and O. A. Ojesanmi, “Accurate Skin Lesion Classification Using Multimodal Learning on the HAM10000 and ISIC 2017 Datasets,” *medRxiv*, 2025.
- [7] Y. Yuan, M. Chao, and Y. C. Lo, “Automatic Skin Lesion Segmentation Using Deep Fully Convolutional Networks With Jaccard Distance,” *IEEE Transactions on Medical Imaging*, vol. 36, no. 9, pp. 1876-1886, 2017.
- [8] D. Shamia, A. M. Ali, and M. S. Ahmed, “Enhancing Skin Cancer Classification with Mixup Data Augmentation and Efficientnet,” *Document Preprint*, 2025.
- [9] S. T. Mahajan and P. Dashore, “Hybrid Deep Learning Models for Skin Lesion Classification: A Comparative Review and Future Directions,” *EPJ Web of Conferences*, vol. 2025, 2025.

- [10] M. A. Khan et al., “A two-stream deep neural network-based intelligent system for complex skin cancer types classification,” *International Journal of Intelligent Systems*, vol. 36, no. 10, pp. 6153-6175, 2021.
- [11] A. Shams, N. A. Riza, and M. S. Hossain, “Skin disease classification: a comparison of Resnet50, Mobilenet, and Efficient-B0,” *Journal of Clinical and Medical Research*, vol. 1, no. 1, pp. 1-7, 2025.
- [12] A. Morales-Forero et al., “An insight into racial bias in dermoscopy repositories: A HAM10000 data set analysis,” *JEADV Clinical Practice*, 2024.
- [13] N. Gessert, M. Nielsen, M. Shaikh, R. Werner, and A. Schlaefer, “Skin lesion classification using ensembles of multi-resolution EfficientNets with meta data,” *Medical Image Analysis*, vol. 64, p. 101764, 2020.
- [14] H. Shaheen, A. K. Singh, and S. Kumar, “Advanced skin lesion detection via efficient-NetBO and vision transformer model with spatial-aware attention,” *Multimedia Tools and Applications*, 2025.
- [15] P. Tschandl, C. Rosendahl, and H. Kittler, “The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions,” *Scientific Data*, vol. 5, no. 1, pp. 1-9, 2018.
- [16] P. S. Reddy, “Skin Lesion Classification Using Vision Transformers on the ISIC 2018 Dataset,” *TechRxiv*, 2026.
- [17] O. P. Yanchatuña, M. A. V. Potosí, and C. A. E. López, “Skin Lesion Detection and Classification Using Convolutional Neural Network for Deep Feature Extraction and Support Vector Machine,” *IEEE Latin America Transactions*, 2021.
- [18] M. G. Dahmani et al., “Vision Transformers (ViT) for Enhanced Skin Cancer Classification,” *Preprint*, 2024.

- [19] K. Mader, “Skin Cancer MNIST: HAM10000,” Kaggle. [Online]. Available: <https://www.kaggle.com/datasets/kmader/skin-cancer-mnist-ham10000>.
- [20] Google, “Google Colaboratory,” [Online]. Available: <https://colab.research.google.com/drive/1GobIvkTMTYUSMAcrztKMCIhiz-O0RMyz?usp=sharing>.
- [21] Overleaf, “Collaborative LaTeX Editor,” [Online]. Available: <https://www.overleaf.com/>.
- [22] Jenni AI, “Jenni AI: Literature Review Generator,” [Online]. Available: <https://jenni.ai/>.
- [23] ResearchRabbit, “ResearchRabbit: The most powerful discovery app ever built for researchers,” [Online]. Available: <https://www.researchrabbit.ai/>.
- [24] Google, “Google Scholar,” [Online]. Available: <https://scholar.google.com/>.
- [25] TÜBİTAK ULAKBİM, “DergiPark Akademik,” [Online]. Available: <https://dergipark.org.tr/>.